

2026/09/16

学术期刊结构化技术创新大赛 · 选题一

Word2JATS：面向学术出版的 Word 智能结构化转换

JiangLab

需求分析与问题定义

需求范围

IMR Press 21 本期刊

研究论文、综述、社论、病例报告、
读者来信、手术技术等多种文章类型

IMR Press / Word 模板

AP/	FBS/	JIN/
BJHM/	GHM/	JMCM/
BP/	HSF/	KO/
CEOG/	IJP/	MRev/
DJNB/	IJVNR/	Pharmazie/
FBE/	JEEMS/	RCM/
FBL/	JFSFQ/	RN/

问题定义

输入 Word 文档（.docx）




输出 JATS 1.3 XML
+ 附属资源包（ZIP）

转换要求

保留原文内容，识别章节与内容对象；
建立作者、单位、图表与文献的关联；
生成 XML，并配齐附属资源。

样例清点与评价依据



样例组成

01–05：5 例
Word 文档+上线 XML

S01–S05：5 例
Word 文档

结构参考构建

以 Word 原文确定内容
结合 JATS 规范整理结构
标注字段、对象及关联

上线 XML 辅助理解
出版标记

评价方法

按内容与关系匹配
兼容等价的 JATS 表达

计算精确率与召回率
另行核对文字、原生公式
及图片资源

10

例样例

64

位作者

167

个章节

35


幅图

46

张表

525

条参考文献



技术选型：三类转换方案的比较


大语言模型（LLM）用于理解上下文、识别内容角色与关系。

比较项	规则驱动转换	大模型辅助转换	智能体自主转换
处理方式	正则匹配 模板映射	程序编排，LLM 识别 程序生成 JATS	LLM 规划步骤 并调用工具
主要优势	处理快 资源消耗低	上下文识别 与流程控制相结合	流程灵活，易拓展 可自主调整处理步骤
主要代价	依赖领域规则 体例变化难维护	控制识别误差 与调用耗时	多轮调用，耗时 与资源更难预估
适用特点	格式约束明确 体例稳定	内容类别明确 排版写法多样	处理步骤不确定 需要探索


本项目选择：大模型辅助转换

LLM 判断角色与关联，程序解析原稿、组织任务并生成 JATS XML。

总体流程：从 Word 解析到 JATS 输出



文首题名、作者及机构信息：限定原稿区域生成局部 JATS，并作专门校验。




核心方法： LLM 识别结构，程序取回原文

原文	LLM 识别	程序组装
2. Materials and Methods	角色： 章节标题 位置： doc/p30 原文片段： 2. Materials and Methods	<pre><sec id="S2"> <title> 2. Materials and Methods </title> <p>.....</p> </sec></pre>

精确匹配 → 表示差异归一化 → 上下文与顺序消歧


依据原稿位置取回标题、正文与文献字段，保留文字、行内格式及来源位置。



图表、公式与参考文献的转换

内容	处理方法	输出
原生表格	读取行列与合并关系	JATS 表格网格
文本排表	将原文片段分配到对应单元格	JATS 表格网格
图片与复合图	保留资源，关联图号、图注与子图	图对象与配套图片
数学公式	原生公式转 MathML；图像或复杂排版 公式保留可读载体	行内、行间公式及编号
参考文献	识别条目边界，再提取著录字段	结构化或混合著录
正文引用	按编号或作者一年份匹配目标	连接文献、图表的引用

文档切分与并行调度




长文处理

按输入预算分窗
保留相邻上下文
按原稿位置归并

并发控制

LLM 并发上限：32
异常请求限次重试




转换质量：内容、结构与关系

10 例样例 · 两种大模型配置的分项召回率与完整性检查

评价项	Qwen	DeepSeek
题名、作者及单位关联、通讯信息、 ORCID 、日期	各项 100%	各项 100%
摘要、关键词、章节及顺序	各项 100%	各项 100%
术语释义与文末声明	各项 100%	各项 100%
图对象、图注、图片归属与图表引用	各项 100%	各项 100%
表对象、表题 / 表注	100% / 93.94%	100% / 93.94%
表格网格位置与内容	77.34%	93.26%
原生公式数学树 / 公式图片	26/26 ； 2/2	26/26 ； 2/2
文献条目 / 文献著录字段	100% / 99.06%	100% / 96.83%
正文—文献引用关系	92.41%	94.12%
全文词项保留率	99.73%	99.71%
JATS DTD 合法文档	10/10	10/10
导出媒体原字节一致性	50/50	50/50

转换效率与调用成本



10 例样例 · Qwen 与 DeepSeek 两种大模型配置

类别	指标	Qwen	DeepSeek
大模型配置	主流程	qwen3.7-plus	deepseek-flash
	文首元信息	qwen3.8-max	deepseek-flash
转换耗时 秒	平均值	135.90	58.27
	中位数	92.31	27.34
Token 用量 10 例合计	输入合计	5,815,531	5,302,342
	其中：缓存命中	2,660,992	5,175,210
	其中：缓存未命中	3,154,539	127,132
	输出	928,179	993,918
	输入+输出	6,743,710	6,296,260
调用费用 元（折算）	篇均	1.1839	0.8413
	10 例合计	11.8391	8.4126

原稿对照与信息校订

文章目录

章节与图表

查找目录内容

文章信息

摘要

Background:

Methods:

Results:

Conclusions:

摘要

1. Introduction

2. Methods

2.1 Study Design and Population

2.2 Clinical Data Collection

2.3 RPP Calculation

2.4 Follow-Up and Clinical Outcomes

2.5 Statistical Analysis

3. Results

3.1 Baseline Characteristics

Table 1.

3.2 Association between RPP and Primary Outcomes

Fig. 1.

转换结果

已更新至保存版本

Early Cardiac Workload and Long-Term Prognosis After Intracerebral Hemorrhage: Insights from a Large Multicenter Cohort

Chuanying Wang

Yunyi Hao

Zeqiang Ji

Anxin Wang

Xiaoli Zhang

Yujie Zhou

Kaijiang Kang

Email: kangkaijiang678@126.com

Department of Neurology, Beijing Tiantan Hospital, Capital Medical University

No. 119 South 4th Ring West Road, Fengtai District, Beijing 100070, China.

+861059975701

Xingquan Zhao

修改后保存到 XML

出版信息

对照原稿 文章信息

切换查看时保留输入

填写后会更新当前 XML。刊名和至少一个 ISSN 用于补全期刊信息。

选择已配置期刊

Reviews in Cardiovascular Medicine

DOI

10.31083/RCM49651

期刊名称

Reviews in Cardiovascular Medicine

印刷版 ISSN

1530-6550

电子版 ISSN

2153-8174

出版方

IMR Press

未作修改

取消

保存修改

预览与定位

按章节、图表、公式和文献浏览结果，查看引用目标。

对照与修改


对照 Word 原稿，修改题名、作者与机构，补充期刊和 DOI。

保存与交付

修改写入 XML；重新检查，预览与下载同步更新。



在线演示



Word2JATS

01 上传 Word → 02 转换与预览 → 03 对照与校订 → 04 下载成果

交付文件 JATS XML + 附属资源包（ZIP）

在线原型 word2jats.jianglab.work

THE END
谢谢