

学术期刊结构化技术创新大赛 · 选题一

# Word2JATS

面向学术出版的 Word 智能结构化转换

**JiangLab**

2026 年 9 月 16 日

# 需求分析：多期刊、多文章类型

## 业务范围

IMR Press 21 本期刊  
作者指南与公开 Word 模板

研究论文、综述、社论、病例报告、  
读者来信、手术技术等

- Microsoft Word Case Report Template-HSF.docx
- Microsoft Word Editorial Template-HSF.docx
- Microsoft Word Original Research Template-HSF.docx
- Microsoft Word Reviews Template-HSF.docx
- Microsoft Word Surgical Technique Template-HSF.docx

## 转换要求

**内容识别** 题名、作者、摘要、关键词、章节、列表、  
图表、公式、参考文献及文末声明

**关系建立** 作者与单位、章节层级、  
正文与图表、正文与文献

**成果交付** 保留原文内容，建立 JATS 结构，  
配齐图片资源

Word 文档（.docx） → JATS Journal Publishing 1.3 XML + 图片资源包

# 样例分析与结构参考构建

## 样例组成

01–05：5 例  
Word 文档+上线 XML

S01–S05：5 例  
Word 文档

## 结构参考构建

以 Word 原文确定内容  
结合 JATS 规范整理结构  
标注字段、对象及关联

上线 XML 辅助理解  
出版标记

## 评价方法

按内容与关系匹配  
兼容等价的 JATS 表达

计算精确率与召回率  
另行核对文字、原生公式  
及图片资源

**10**

例样例

**64**

位作者

**167**

个章节

**35**

幅图

**46**

张表

**525**

条参考文献

# 技术选型：三类转换方案的比较

大语言模型（LLM）用于理解上下文、识别内容角色与关系。

| 比较项  | 规则驱动转换           | 大模型辅助转换                  | 智能体自主转换            |
|------|------------------|--------------------------|--------------------|
| 处理方式 | 规则识别<br>模板映射     | 程序编排，LLM 识别<br>程序生成 JATS | LLM 规划步骤<br>并调用工具  |
| 主要优势 | 处理快<br>资源消耗低     | 上下文识别<br>与流程控制相结合        | 根据问题<br>动态调整处理路径   |
| 主要代价 | 体例变化需要<br>维护识别规则 | 控制识别误差<br>与调用耗时          | 多轮调用，耗时<br>与资源更难预估 |
| 适用特点 | 格式约束明确<br>体例稳定   | 内容类别明确<br>排版写法多样         | 处理步骤不确定<br>需要探索    |

## 本项目选择：大模型辅助转换

LLM 判断角色与关联，程序解析原稿、组织任务并生成 JATS XML。

# 总体流程：从 Word 解析到 JATS 输出



文首题名、作者及机构信息：限定原稿区域生成局部 JATS，并作专门校验。

# 核心方法： LLM 识别结构，程序取回原文

| 原文                              | LLM 识别                                                          | 程序组装                                                                                                                                 |
|---------------------------------|-----------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------|
| <b>2. Materials and Methods</b> | 角色：章节标题<br>位置： doc/p30<br>原文片段：<br><br>2. Materials and Methods | <pre>&lt;sec id="S2"&gt;   &lt;title&gt;     2. Materials and Methods   &lt;/title&gt;   &lt;p&gt;.....&lt;/p&gt; &lt;/sec&gt;</pre> |

精确匹配 → 表示差异归一化 → 上下文与顺序消歧


依据原稿位置取回标题、正文与文献字段，保留文字、行内格式及来源位置。

# 图表、公式与参考文献的转换

| 内容     | 处理方法                               | 输出         |
|--------|------------------------------------|------------|
| 原生表格   | 读取行列与合并关系                          | JATS 表格网格  |
| 文本排表   | 将原文片段分配到对应单元格                      | JATS 表格网格  |
| 图片与复合图 | 保留资源，关联图号、图注与子图                    | 图对象与配套图片   |
| 数学公式   | 原生公式转 MathML ； 图像或复杂排版<br>公式保留可读载体 | 行内、行间公式及编号 |
| 参考文献   | 识别条目边界，再提取著录字段                     | 结构化或混合著录   |
| 正文引用   | 按编号或作者一年份匹配目标                      | 连接文献、图表的引用 |

对象内容、原文顺序与关联关系共同进入输出。

# 文档切分与并行调度



## 长文处理

按输入预算分窗  
保留相邻上下文  
按原稿位置归并

## 并发控制

LLM 并发上限： 32  
异常请求限次重试

# 转换质量：内容、结构与关系

## 10 例样例 · 两种大模型配置的分项召回率与完整性检查

| 评价项                        | Qwen          | DeepSeek      |
|----------------------------|---------------|---------------|
| 题名、作者及单位关联、通讯信息、 ORCID 、日期 | 各项 100%       | 各项 100%       |
| 摘要、关键词、章节及顺序               | 各项 100%       | 各项 100%       |
| 术语释义与文末声明                  | 各项 100%       | 各项 100%       |
| 图对象、图注、图片归属与图表引用           | 各项 100%       | 各项 100%       |
| 表对象、表题 / 表注                | 100% / 93.94% | 100% / 93.94% |
| 表格网格位置与内容                  | 77.34%        | 93.26%        |
| 原生公式数学树 / 公式图片             | 26/26 ； 2/2   | 26/26 ； 2/2   |
| 文献条目 / 文献著录字段              | 100% / 99.06% | 100% / 96.83% |
| 正文一文献引用关系                  | 92.41%        | 94.12%        |
| 全文词项保留率                    | 99.73%        | 99.71%        |
| JATS DTD 合法文档              | 10/10         | 10/10         |
| 导出媒体原字节一致性                 | 50/50         | 50/50         |

# 转换效率与调用成本

10 例样例 · Qwen 与 DeepSeek 两种大模型配置

| 类别                 | 指标       | Qwen         | DeepSeek       |
|--------------------|----------|--------------|----------------|
| 大模型配置              | 主流程      | qwen3.7-plus | deepseek-flash |
|                    | 文首元信息    | qwen3.8-max  | deepseek-flash |
| 转换耗时<br>秒          | 平均值      | 135.90       | 58.27          |
|                    | 中位数      | 92.31        | 27.34          |
| Token 用量<br>10 例合计 | 输入合计     | 5,815,531    | 5,302,342      |
|                    | 其中：缓存命中  | 2,660,992    | 5,175,210      |
|                    | 其中：缓存未命中 | 3,154,539    | 127,132        |
|                    | 输出       | 928,179      | 993,918        |
|                    | 输入 + 输出  | 6,743,710    | 6,296,260      |
| 调用费用<br>元（折算）      | 篇均       | 1.1839       | 0.8413         |
|                    | 10 例合计   | 11.8391      | 8.4126         |

# 原稿对照与信息校订

文章目录

章节与图表

查找目录内容

文章信息

摘要

Background:

Methods:

Results:

Conclusions:

摘要

1. Introduction

2. Methods

2.1 Study Design and Population

2.2 Clinical Data Collection

2.3 RPP Calculation

2.4 Follow-Up and Clinical Outcomes

2.5 Statistical Analysis

3. Results

3.1 Baseline Characteristics

Table 1.

3.2 Association between RPP and Primary Outcomes

Fig. 1.

转换结果

已更新至保存版本

Early Cardiac Workload and Long-Term Prognosis After Intracerebral Hemorrhage: Insights from a Large Multicenter Cohort

Chuanying Wang

Yunyi Hao

Zeqiang Ji

Anxin Wang

Xiaoli Zhang

Yujie Zhou

Kaijiang Kang

Email: kangkaijiang678@126.com

Department of Neurology, Beijing Tiantan Hospital, Capital Medical University

No. 119 South 4th Ring West Road, Fengtai District, Beijing 100070, China.

+861059975701

Xingquan Zhao

修改后保存到 XML

出版信息

对照原稿 文章信息

切换查看时保留输入

填写后会更新当前 XML。刊名和至少一个 ISSN 用于补全期刊信息。

选择已配置期刊

Reviews in Cardiovascular Medicine

DOI

10.31083/RCM49651

期刊名称

Reviews in Cardiovascular Medicine

印刷版 ISSN

1530-6550

电子版 ISSN

2153-8174

出版方

IMR Press

未作修改

取消

保存修改

## 预览与定位

按章节、图表、公式和文献浏览结果，查看引用目标。

## 对照与修改

对照 Word 原稿，修改题名、作者与机构，补充期刊和 DOI。

## 保存与交付

修改写入 XML；重新检查，预览与下载同步更新。

# 在线演示

## Word2JATS

01 上传 Word → 02 转换与预览 → 03 对照与校订 → 04 下载成果

---

交付文件      JATS XML + 图片资源包 figures.zip

在线原型      [word2jats.jianglab.work](http://word2jats.jianglab.work)