

word2jats：面向学术出版的 Word 智能结构化转换

学术期刊结构化技术创新大赛 · 选题一 · 技术方案说明书

参赛团队：JiangLab

在线原型：<https://word2jats.jianglab.work>

一、项目目标与方案概述

1.1 从投稿文档到出版数据

学术论文在 Word 中主要通过排版表达含义：标题的字体和位置体现章节层次，作者姓名后的角标对应单位或通讯说明，表格的合并单元格表达分组关系，正文中的编号指向图表与参考文献。出版系统需要的则是能够检索、链接、重用和重新排版的结构化数据。Word 转换为 JATS XML 的关键，是把这些隐含关系恢复为明确的出版结构，同时保留论文内容。

word2jats 面向这一过程，接收 DOCX 稿件，生成符合 JATS Journal Publishing 1.3 的 XML 文档及配套图片资源，并提供网页校样、原稿对照、复核记录和结果导出。编辑可以在同一工作台完成稿件提交、结构化转换和结果检查；技术人员也可以通过命令行调用相同的转换流程。

项目将任务分为三个相互关联的目标。第一是内容完整：文字、数字、图表和公式在转换中有明确去向。第二是结构可用：章节、作者单位、文献字段和交叉引用能够被出版系统直接读取。第三是加工高效：利用模型完成语义识别，利用程序完成重复性组装与检查，并将需要编辑判断的事项定位到原稿。

1.2 技术路线与主要贡献

方案采用“语义识别与内容取回分离”的设计。模型读取带位置标识的原稿清单，判断内容角色、边界和关联；程序将定位线索解析为原稿中的字符范围，再据此组织正文、摘要与文献等内容。作者、单位及通讯关系使用受约束的文首生成流程，适配复杂的关系结构。

这一设计形成三项相互支撑的技术贡献：

- 以原文位置连接识别与生成。模型的结构判断可以调整，正文与文献的内容取回仍依据 Word 原稿；同一位置表示也用于后续检查和原稿定位。
- 以内容对象组织整篇论文。统一处理文字范围、表格网格、图片与公式的出现位置，以及作者、图表、文献之间的关系，完成从局部识别到整篇 JATS 文档的组装。
- 以任务依赖和编辑流程组织自动化。文首、正文、文献与引文按依赖并行处理；生成结果进入可视化校样，编辑能够查看原文、处理具体事项并导出成果。

原型提供 Qwen 与 DeepSeek Flash 两种模型配置。模型适配、用量计量、XML 生成与编辑操作使用统一接口，便于根据转换质量、时间和资源消耗选择运行配置。

二、总体架构与数据组织

2.1 分层处理流程

系统划分为原稿解析、结构理解、定位组装、生成检查和编辑工作台五个部分。它们之间传递的是带有原稿位置和对象身份的数据，而不只是中间文本。




图1 系统总体架构

原稿解析层读取 DOCX 的文字、样式、编号、表格和嵌入资源，形成统一的原稿记录。结构理解层对这些记录进行任务化识别。定位组装层将各任务结果归并为语义文档，生成层再将语义对象映射为 JATS 元素，外部化图片并建立引用。自动检查和网页复核围绕同一份输出展开。

这套分工兼顾了两类信息：一类是 Word 中可以直接读取的事实，例如单元格合并、图片字节和公式对象；另一类是需要结合上下文理解的含义，例如一行文字究竟是章节标题、图注还是作者单位。前者由程序解析，后者由模型识别，二者在组装阶段结合。

2.2 原稿记录：位置、内容与对象分开表示

解析器为段落、表格单元格及附属文本建立稳定地址。例如，doc/p30 表示正文部件中的一条段落记录；一段文字进一步用“记录地址、起始位置、结束位置”定位。字符范围采用左闭右开的表示，范围内的内容可以直接从原稿取回。

模型输入清单保留记录地址，并附带有效格式、提纲级别、编号等信息。Word 样式先经过继承关系解析，再作为识别依据提供给模型。因此，标题识别既能利用 Word 已有结构，也能结合上下文处理不规范样式，而不依赖固定的样式名称。

图片和公式分别记录“资源”与“出现位置”。资源对应实际字节或原生公式内容；出现位置说明它位于哪段文字、哪个单元格，以及在文档中出现的顺序。同一图片被引用多次时，可以复用资源并保留多个位置；一张复合图由多个图像组成时，也可以归入同一个图对象。

2.3 语义文档与 JATS 映射

各识别任务的结果最终归并为统一的语义文档。语义对象包括章节、段落、图、表、公式、注释、定义列表、文献条目和引用关系。文字对象引用原稿范围，图片对象引用资源出现记录，关系对象引用目标实体。

稿件内容	中间表示的重点	JATS 输出结构
题名、作者、单位、通讯信息	字段与人员、机构的关联	article-meta、contrib、aff、author-notes
摘要与关键词	摘要分段、分节及各关键词的原文位置	abstract、sec、kwd-group
章节与正文	标题层级、段落顺序、行内格式	body、sec、title、p
表格	行列、合并区域、表头、表题和表注	table-wrap、table、thead、tbody
图片与复合图	图对象、组成图片、编号与图注	fig、fig-group、graphic、caption
数学公式	行内或行间位置、数学结构或图像载体	inline-formula、disp-formula、MathML
定义列表与文末声明	术语—释义关系、声明标题与内容	def-list、def-item、ack、fn-group 等
文献与交叉引用	条目、著录字段、引用位置与目标	ref-list、ref、element-citation、xref

生成器统一分配内部标识，并将原稿中的显示编号与内部身份分开管理。例如，正文可保留 “[6–8]” 的原有写法，同时通过一个引用元素关联三条文献实体。显示形式与机器可读取的关系可以同时保留。

三、核心转换方法

3.1 原文定位与内容组装

结构识别的输出包括记录地址、原文摘抄以及必要的前后文。程序先在指定记录中精确查找摘抄；遇到空白、引号或连字符的等价写法时，进行受控归一化匹配；出现重复文字时，再结合位置线索、邻接内容和先后顺序确定对应范围。最终用于组装的文字取自匹配到的原稿位置。

例如，一份稿件中的 doc/p30 记录为 “2. Materials and Methods”。正文任务将其识别为章节标题，组装器保留该记录的文字并建立章节对象，生成如下结构（省略正文）：

```
<sec id="S2">
  <title>2. Materials and Methods</title>
  <p>.....</p>
</sec>
```

其中，章节角色由模型判断，标题文字由原稿取回，章节标识由生成器分配。对于同一段落内的部分文字，例如参考文献中的题名、年份或正文中的一处引文，则定位到字符子区间。这样既能进行细粒度标注，也能保留未被标注的上下文。

多个任务可能对相邻区域作出不同判断，系统会在整篇组装前归并角色与范围，处理文首、正文、图表说明和文献之间的边界冲突。生成后还会核对各范围的使用情况，使局部处理能够与全文内容衔接。

3.2 文首元信息、作者与通讯关系

文首处理先确定元信息区域和摘要关键词区域，再分别处理两类内容。元信息不仅是若干字符串，还包含关系：一位作者可以属于多个机构，多位作者可以共享一个单位，通讯说明可能位于单独段落，ORCID、邮箱和个人地址也可能分散出现。

模型依据限定的文首区域生成局部 JATS 结构，将姓名、学位、标识和角色归入对应人员，将机构信息组织为 aff，并以 xref 连接作者、单位和通讯说明。姓名可以可靠拆分时使用姓与名字段；适合整体表示时采用 string-name。日期按照收稿、修回、录用等事件类型组织，而非依赖原稿中日期分量的书写顺序。

局部结果经过 JATS 内容模型校验；结构错误会连同具体校验信息返回模型修正。生成器还核对原稿内容及标识，处理格式角标与相邻文字的边界，并记录需要复核的修正。ORCID 作为人员标识保留在 contrib-id 中，作者姓名、单位关联和通讯关系分别参与质量评价。

摘要和关键词采用原文定位方式。结构化摘要识别各小节的标题与内容；普通摘要保留段落组织；图文摘要保留与其对应的图片资源；关键词按各词项的范围生成 kwd。这些内容与文首元信息可以在边界确认后并行处理。

3.3 正文章节、格式与特殊内容

正文任务结合全文上下文和 Word 格式事实，判断章节标题、普通段落、图表说明、公式及文末声明等角色。章节层级由内容与排版信息共同确定，随后按照原稿顺序建立章节树。图题、表题、摘要标题与正文标题分别归属对应对象，避免仅凭加粗或居中样式将它们归入同一种结构。

行内格式与文字内容一同按原稿范围取回。生成时，根据语义位置处理格式：章节标题的整体外观可以由预览样式控制；正文中实际承载含义的斜体、上下标等保留为行内标记；数学对象进入公式结构。Word 自动编号从编号定义读取，用于恢复文献等条目的显示编号。

术语表与定义列表按术语—释义关系组织；作者贡献、利益冲突、伦理、数据可用性及资助等声明，按识别到的标题和所属内容生成文末结构。处理重点是保留原文内容和先后关系，同时让不同业务内容具有可识别的结构位置。

3.4 表格：保留逻辑网格，恢复文本排表

Word 稿件中的表格具有不同载体。原生表格已经包含行、列和合并关系，系统读取这些结构事实，按逻辑网格生成 JATS 表格。横向和纵向合并分别映射为列跨度和行跨度；表头、行头、表题及表注由结构理解结果补充。单元格内的文字、上下标和公式继续使用相同的内容取回机制。

另一类表格以制表符、空格或软换行排出，原文件中没有完整单元格结构。系统先识别属于该表的实际文本行，再由专项任务将每行中的原文片段分配到各列。程序核对片段归属和使用情况：同一行的内容应完整进入对应单元格，各片段不得相互重叠或被重复使用。识别结果据此转为行列结构，并保留核对信息供编辑处理。

图像型表格则保留其图片载体，配合表题、编号和表注生成 table-wrap。在界面上，三类表格都进入校样预览；结构化网格可直接用于后续排版，文本排表中的疑难项目可结合原稿摘录核对。实验分别考察表格对象、题注和网格单元内容，体现“表存在”和“表结构正确”的不同要求。

3.5 图片、复合图与数学公式

图片处理同时解决资源和语义归属。系统从 DOCX 的关联关系取得图片，记录其出现位置，再将图片归入对应的图、表或段落。一张图包含多个面板时，保持组成关系和先后顺序；图编号、图注标题和解释段落分别组织。媒体文件按原字节导出，并将 XML 中的资源路径关联到实际文件。

公式按照载体处理。Word 原生公式使用 Office Math Markup Language (OMML) 表达数学结构；系统通过样式表转换为 MathML，并递归组织运算节点。一次变换可能产生多个并列节点，所有节点共同构成完整的数学表达式。行内公式和行间公式分别放入 JATS 对应容器，公式编号与正文引用也保留其关联。

图像型公式使用原始图片承载，放入公式容器并保留其段内位置。例如，同一行公式由两个 WMF 片段组成时，两个资源均参与输出。网页针对 TIFF 和可解码的 WMF 提供浏览器可显示的预览，下载包保留原始文件。由此，预览显示与出版资源交付可以分别满足使用要求。

原生公式的实验同时核对数量与数学树结构；图像型公式核对载体是否保留。这两类结果分别报告，以对应可继续进行数学处理的结构化公式和保留原貌的图像公式。

3.6 参考文献：边界识别、字段提取与完整著录

参考文献处理分成两个阶段。首先识别条目边界，两路不同提示分别给出判断；程序将边界定位回原稿，对一致结果直接归并，对分歧进行裁决。条目的身份由其原稿范围确定，编号作为独立的显示信息处理，因此既可以处理显式编号，也可以处理 Word 自动编号或无编号著录。

边界确定后，各条文献并行提取人员、题名、刊名、年份、卷期页、标识和出版信息等字段。字段摘抄需要定位到原稿范围；姓名等重复片段还结合成员范围、顺序与不重叠条件进行分配。原稿已能唯一确定字段位置时直接采用；确有歧义时，再利用模型的顺序提示辅助判断。输出中的字段先后以实际原稿位置为准。

例如，著录片段“European Journal of Preventive Cardiology, 26 (2019) 1191-1204.”分别提供刊名、卷号、年份和起止页。模型返回这些原文片段，程序核对位置并生成下列字段；其中卷号位于年份之前，与原稿一致：

```
<source>European Journal of Preventive Cardiology</source>
<volume>26</volume><year>2019</year>
<fpage>1191</fpage><lpage>1204</lpage>
```

这些字段与人员、题名等共同进入 element-citation，成为可以单独检索、链接和重新排版的出版数据。

字段化过程同时核对整条著录的内容覆盖。著录中的常规标点和连接记法按明确规则处理，其余内容需要由相应字段承载。对于不适合充分拆分的条目，系统使用 mixed-citation 保留整条原文，完整著录仍可在原稿中查看和核对。两种形式都具有 JATS 中的合法承载方式，条目完整性与字段化程度分别统计。

3.7 正文引文与图表关联

引文识别任务给出正文中的引用位置与目标线索。数字制引用通过原稿显示编号关联文献实体；作者—年份制引用结合作者、年份与引用摘抄匹配目标。对图表的提及则关联对应图、表实体。所有目标在组装阶段转换为文档内部标识。

例如，正文中的“[6–8]”可表示为以下片段，括号保留在周围文字中：


```
<xref ref-type="bibr" rid="R006 R007 R008">6–8</xref>
```

这既保留原来的显示范围，也建立三条机器可读的引用关系。输出检查验证标识唯一性及目标存在性；质量评价进一步按所在段落、引用位置和实际目标进行匹配。这样可以分别衡量链接是否有效，以及它是否指向应当关联的内容。

四、运行效率与工程实现

4.1 依据实际依赖进行并行调度

一次转换包含多个模型任务，它们对输入结果的依赖并不相同。文首、正文、文献边界和正文引文均可以读取原稿清单并独立开始；文献字段提取只需要文献边界结果；文本表格恢复需要完成正文角色归并；最终组装再汇合所有必要结果。



箭头表示实际数据依赖；同一转换进程内的模型请求共用并发上限

图2 单篇稿件内部的任务依赖

系统据此组织并行执行。文献字段提取在边界确认后立即启动，与文首及正文的后续处理重叠；文本表格恢复期间，文献字段和引文识别仍可继续运行。等待被限制在实际存在的数据依赖上。

模型请求共用进程级并发上限，默认最多 32 个在途请求。即使文首与正文采用不同客户端实例，也遵守同一上限。长文按照输入预算划分窗口，并在相邻窗口保留上下文；各窗口结果经过原文定位后归并。通过任务级并行与有界请求并发，兼顾单篇处理时间和服务资源占用。

4.2 完整响应、限次重试与两级复用

模型输出采用流式接收。程序在响应正常结束后再进行 JSON 或 XML 解析，中断的半截回答不会进入组装。传输异常按类型进行有限重试，并遵循服务端给出的退避信息；结构回答未满足契约时，将具体问题返回模型作限次修正。调用次数和用量包含这些实际发生的额外请求。

系统区分两类复用。应用本地缓存保存完整模型回答，按模型、任务、输入与生成参数确定请求身份，相同请求可以直接复用。原稿修订后，只有输入保持一致的任务能够复用，改变的请求重新执行。模型服务端的上下文缓存则针对实际提交的输入计算命中量，仍然属于一次真实模型调用。两者分别记录，避免将本地复用次数与缓存 Token 混淆。

Token 用量统一记录输入、输出、缓存命中、缓存未命中及总量。原始数据取自模型响应，输入总量划分为缓存命中与未命中两部分。逐请求记录汇总到各模型和整篇稿件，界面与下载包采用一致字段。

4.3 可维护的实现与运行方式

转换核心使用 Python，按解析、理解、语义对象、生成、检查和模型接入划分模块。模型提供结构判断，生成器负责标准输出，网页和命令行调用同一个转换入口。因此，调整模型配置不会改变输入文件格式、校样操作或成果格式。

网页采用 FastAPI 提供上传、任务状态、预览、复核保存和下载接口。转换在后台执行，前端可以持续显示进度；大文件采用分片上传和失败重传，并在合并后校验大小与摘要。模型凭据保存在服务端配置中。

每次转换使用独立工作目录，先生成候选 XML 与媒体，再完成结构、内容和资源检查。检查通过后发布结果；需要处理的候选仍保留为可预览的成果，关联具体问题。生成与发布分开，有助于保护已有成果，并使异常处理中保留足够的上下文。

调用适配层按模型支持的响应格式传递统一的输出结构要求，理解层执行相同的本地契约检查。程序通过云端接口使用语言模型，本机承担 DOCX 解析、任务编排、XML 生成、检查和网页服务，不需要部署本地模型权重或 GPU。安装 Python 依赖并配置模型凭据后，可使用 `python -m webapp` 启动工作台，也可以通过命令行处理单篇稿件。运行说明、输入输出示例和依赖清单随原型提供。

4.4 内容与结构的联合检查

自动检查分为四组。格式检查验证 XML 良构及 JATS DTD；关系检查验证 ID 唯一性和引用目标；资源检查验证媒体文件存在、格式可识别、字节与原稿一致；内容检查利用原稿范围和输出来源记录，核对原文去向及生成内容的依据。

这套检查与语义识别互补。识别阶段建立章节、字段和关系，检查阶段验证这些结果是否构成完整、可用的成果。检查信息进一步转为编辑工作台中的具体事项，并与原稿摘录关联，形成可操作的校样入口。

五、原型与编辑工作流程

5.1 一次稿件处理的操作过程

编辑上传 Word，按需要补充 DOI 与期刊信息，并选择处理模型。系统识别完成后，工作台同时提供成品预览、原文核对、内容清单、合规检查和 XML 源文件五个视图。

成品预览以阅读论文的方式呈现章节、图表、公式和文献，支持在结构化结果中浏览关联内容。内容清单帮助编辑检查作者、图表及文献等对象；XML 视图供技术人员核查具体标记。不同视图共用同一份转换结果，编辑无需在多个工具之间重新组织稿件。



图3 稿件校样工作台

5.2 把复核工作定位到原稿

需要核对的事项按内容组织，并给出对应的原稿摘录和处理建议。编辑可以针对具体事项记录“待核对”“已核对，保留当前结果”或“需修改后重新转换”，同时填写备注和复核人。

例如，参考文献未充分拆分字段时，编辑可以对照完整著录判断是否满足交付要求；文本表格需要整理时，可以依据原稿摘录在 Word 中调整行列，再重新转换。相同原段落中的同类提示会合并呈现，减少重复阅读。

复核记录与当前 XML 的文件摘要绑定，导出时注明对应版本。原稿修订、自动转换和编辑确认由此形成连续的加工过程，处理意见能够随成果交接。

逐项核对 · 4 项

结合原稿摘录检查成品，记录处理意见。需要修改时，请调整 Word 原稿后重新上传复验。

1. 已整理表头内的排版表格

✓ 建议核对

2. 已整理表头内的排版表格

✓ 建议核对

3. 参考文献保留了完整原文

✓ 建议核对

该条未完全拆成作者、题名、年份等字段，请核对其著录结构。

原稿摘录

[14] Readability formulas. The Flesch reading ease readability formula Retrieved fromhttp://www.readabilityformulas.com/flesch-reading-ease-readability-formula.php

处理结论

待核对

▼

复核备注

记录判断依据或待修改内容

4. 参考文献保留了完整原文

✓ 建议核对

复核人（可选）

保存复核记录

复核记录会附在下载包中。记录处理意见不会改动 XML，也不会自动改变检查结论。

图 4 原稿摘录与逐项复核

5.3 统一输出与用量可见

成果包包含 JATS XML、配套媒体、转换用量，以及已保存的人工复核记录。Qwen 与 DeepSeek 配置提供相同的操作界面和成果结构；本次转换的输入、输出和缓存用量在结果页展开查看，并同步进入下载包。

技术方案将编辑判断安排在可定位的具体事项上：模型与程序完成结构化加工，工作台提供对照和处理入口，编辑完成专业判断与必要修订。这与期刊的稿件加工、校样确认和成果交接流程相衔接。

六、实验设计与定量结果

6.1 实验设置与评价方法

实验采用同一批学术论文 DOCX，比较 Qwen 组合配置与 DeepSeek Flash 配置。Qwen 组合的主流程使用 qwen3.7-plus，文首使用 qwen3.8-max；DeepSeek 配置使用 deepseek-flash。两组采用相同的原稿解析、语义任务、组装及检查流程，温度设为 0，关闭思考模式，单篇内部请求并发上限为 32。

运行环境为 Linux x86_64、Python 3.12.7，处理器为 AMD EPYC 9334。模型通过各自服务端接口调用，本机不加载模型权重。每种配置对每篇稿件执行一次完整转换，逐篇用量与输出文件对应保存。

各稿件逐篇转换，每篇使用独立的新响应目录，不复用既有模型回答。转换总耗时从程序开始处理 DOCX 计至生成 XML、媒体与检查结果，不包含上传和人工校样时间。模型服务端缓存按运行时的实际命中量记录。

质量评价按内容类型展开。字段和结构以稿件内容及对应结构标注为参照，匹配前统一排版空白、内部 ID 命名和区间引文的等价表示；正文内容保留另从 DOCX 直接读取文字进行核对；原生公式直接读取 OMML 并核对输出数学树；媒体按资源字节及所属图表核对。各项分别统计正确匹配数、应有数和输出数，召回率为“正确匹配数／应有数”，精确率为“正确匹配数／输出数”。

全文文字保留率按归一化后的词项及出现次数核对，包含正文、文首、表格和文献中的文字，以及进入 DOI、ORCID 等专门标签的内容。该指标与结构、公式及引用指标配合使用。Token 消耗是模型接口返回的用量，与文字保留评价中的词项统计分别计算。

6.2 稿件组成与转换质量

本组共 10 篇稿件。表 1 列出各篇的内容规模；图与表按论文中的逻辑对象计数，公式栏分别列出原生公式数与图像载体部件数。Word 文件中的图片大小、文献数量与排表方式各不相同，因此同时保留逐篇结果与整体汇总。

表 1 实验稿件的内容组成

编号	DOCX / MiB	词项数	作者 / 章节	图 / 表	公式 / 图像部件	文献
01	0.79	12,109	3 / 15	1 / 4	10 / 2	39
02	2.08	11,429	5 / 28	4 / 8	0 / 0	69
03	36.87	7,950	9 / 19	5 / 3	16 / 0	56
04	3.25	12,314	7 / 9	2 / 3	0 / 0	145
05	0.20	7,836	4 / 5	4 / 14	0 / 0	27
S01	0.49	6,763	5 / 20	3 / 5	0 / 0	30
S02	2.05	11,653	10 / 25	2 / 2	0 / 0	50
S03	2.58	8,019	6 / 17	4 / 1	0 / 0	22
S04	8.39	7,819	6 / 14	6 / 3	0 / 0	41
S05	3.17	7,155	9 / 15	4 / 3	0 / 0	46

表 2 全文分项结构结果（单元格为“正确匹配数 / 输出数；召回率”）

评价项	应有数	Qwen 组合	DeepSeek Flash
题名	10	10 / 10; 100.00%	10 / 10; 100.00%
作者姓名	64	64 / 64; 100.00%	64 / 64; 100.00%
作者顺序	64	64 / 64; 100.00%	64 / 64; 100.00%
作者单位	36	36 / 36; 100.00%	36 / 36; 100.00%
作者—单位关系	106	106 / 106; 100.00%	106 / 106; 100.00%
通讯作者—邮箱关系	17	17 / 17; 100.00%	17 / 17; 100.00%
作者—ORCID 关系	38	38 / 38; 100.00%	38 / 38; 100.00%
稿件日期	26	26 / 26; 100.00%	26 / 26; 100.00%
摘要内容	12	12 / 12; 100.00%	12 / 12; 100.00%
摘要分段与分节	12	12 / 12; 100.00%	12 / 12; 100.00%
关键词	50	50 / 50; 100.00%	50 / 50; 100.00%
章节层级与标题	167	167 / 167; 100.00%	167 / 167; 100.00%
章节顺序	167	167 / 167; 100.00%	167 / 167; 100.00%
术语—释义条目	62	62 / 62; 100.00%	62 / 62; 100.00%
文末声明与附属章节	57	57 / 57; 100.00%	57 / 57; 100.00%
图对象	35	35 / 35; 100.00%	35 / 35; 100.00%
图注内容	35	35 / 35; 100.00%	35 / 35; 100.00%
表对象	46	46 / 46; 100.00%	46 / 46; 100.00%
表题内容	46	46 / 46; 100.00%	46 / 46; 100.00%
表注内容	33	31 / 33; 93.94%	31 / 33; 93.94%
表格网格位置与内容	2,922	2,260 / 2,375; 77.34%	2,725 / 2,791; 93.26%
图片资源及图表归属	48	48 / 48; 100.00%	48 / 48; 100.00%
原生公式数学树	26	26 / 26; 100.00%	26 / 26; 100.00%
公式图片资源	2	2 / 2; 100.00%	2 / 2; 100.00%
参考文献条目覆盖	525	525 / 525; 100.00%	525 / 525; 100.00%
文献著录字段	3,188	3,158 / 3,168; 99.06%	3,087 / 3,097; 96.83%
正文—文献引用关系	817	755 / 799; 92.41%	769 / 813; 94.12%
正文—图表引用关系	108	108 / 108; 100.00%	108 / 108; 100.00%

正确匹配数与输出数之比即精确率；召回率反映应有内容中得到正确结构化表示的比例。文献字段包括作者名单、题名、刊名、年份、卷期、页码或文章位置、DOI、PMID 及出版者；同一语义字段的标签拆分与等价写法先统一，再进行匹配。引用关系在对齐的可见段落和字符位置上核对实际目标，区间引用展开为各条目标关系。

表 3 整体内容保留与标准符合性

指标	Qwen 组合	DeepSeek Flash
全文文字保留率	99.73%	99.71%
JATS DTD 合法文档	10 / 10	10 / 10
已导出媒体的原字节一致性	50 / 50	50 / 50

分项结果区分了内容保留与结构加工：表题和表对象识别后，还需核对单元格的行列归属；文献条目保留后，还需考察各著录字段与正文引用。编辑工作台据此提供原稿对照和具体核对入口，将自动加工与校样处理连接起来。

6.3 转换耗时与本机资源占用

表 4 逐篇转换耗时及实际模型请求次数

编号	Qwen / 秒	DeepSeek / 秒	Qwen 请求数	DeepSeek 请求数
01	100.78	29.70	51	50
02	145.92	340.24	78	86
03	87.98	29.19	64	64
04	429.68	52.30	159	156
05	225.19	31.60	58	53
S01	61.87	13.03	41	38
S02	86.72	25.48	59	59
S03	46.50	19.86	32	32
S04	77.67	21.77	52	53
S05	96.65	19.49	54	53
平均	135.90	58.27	—	—
中位数	92.31	27.34	—	—

在本组稿件及运行条件下，DeepSeek Flash 的平均转换时间为 Qwen 组合的 42.9%，平均耗时缩短 57.1%。该比较使用相同的转换流程和并发上限，体现两种模型配置在本任务中的整体处理差异。

本机资源仅统计转换进程。CPU 时间为用户态与内核态耗时之和；驻留内存以 0.1 秒间隔采样，取每篇执行期间的峰值。模型推理在服务端完成，本机数据对应文档解析、请求编排、生成及检查。

表 5 本机资源与请求汇总

指标	Qwen 组合	DeepSeek Flash
平均 CPU 时间 / 秒	9.55	23.85
单篇驻留内存峰值范围 / MiB	162.0–270.1	160.1–273.7
模型请求总次数（含重试）	648	644
限流重试次数	2	0

6.4 模型 Token 消耗

以下计量汇总本次转换中实际发生的请求，包含文首专用模型与限次重试。输入总量等于缓存命中与缓存未命中之和，总量为输入与输出之和；缓存命中已包含在输入中，不再重复相加。所有数值均以 Token 为单位。

表 6 Qwen 组合逐篇用量

编号	输入	输出	缓存命中	缓存未命中	总量
01	516,193	62,357	86,016	430,177	578,550
02	600,588	135,549	327,936	272,652	736,137
03	498,410	79,729	323,968	174,442	578,139
04	1,004,845	245,682	302,080	702,765	1,250,527
05	536,634	119,681	77,824	458,810	656,315
S01	445,859	48,550	58,368	387,491	494,409
S02	741,947	74,968	551,296	190,651	816,915
S03	532,232	35,241	324,992	207,240	567,473
S04	469,350	62,876	304,256	165,094	532,226
S05	469,473	63,546	304,256	165,217	533,019
合计	5,815,531	928,179	2,660,992	3,154,539	6,743,710

表 7 DeepSeek Flash 逐篇用量

编号	输入	输出	缓存命中	缓存未命中	总量
01	478,304	66,017	467,446	10,858	544,321
02	572,893	327,078	556,149	16,744	899,971
03	462,398	76,320	448,991	13,407	538,718
04	844,251	177,495	813,231	31,020	1,021,746
05	493,241	73,263	483,189	10,052	566,504
S01	410,265	41,235	403,067	7,198	451,500
S02	683,649	70,606	673,004	10,645	754,255
S03	474,720	39,539	468,093	6,627	514,259
S04	452,484	63,363	441,968	10,516	515,847
S05	430,137	59,002	420,072	10,065	489,139
合计	5,302,342	993,918	5,175,210	127,132	6,296,260

两种接口在本次响应中均未返回费用金额，表中报告实际 Token 用量。

用量差异与分词规则、各任务的输出长度及发生的重试有关。模型配置的选择因此同时参考分项结构质量、逐篇时间和输入输出规模；工作台以统一字段呈现这些信息，操作流程与成果格式保持一致。

6.5 技术价值与应用方式

word2jats 将学术论文转换组织为语义识别、原文取回、标准生成和编辑校样的连续流程。源位置表示贯穿内容组装与原稿核对；多任务并行缩短无依赖步骤之间的等待；统一模型适配和用量统计为运行配置选择提供依据。

输出 XML 与媒体可以作为后续排版、内容检索和出版系统集成的基础，网页原型则提供面向编辑的直接使用入口。项目的应用价值体现在将整篇稿件的重复标注工作自动化，并将专业判断保留在有原稿依据、可记录和可交接的编辑环节中。

使用的标准与组件

输出依据 NLM 发布的 JATS Journal Publishing 1.3 标签库与 DTD。公式转换采用 OMML2MML 样式表；校样预览采用 JATS Preview Stylesheets；XML 处理、文档解析、图片处理与网页服务使用 lxml、python-docx、Pillow 和 FastAPI 等组件。团队实现原稿记录与语义组织、模型任务编排、原文定位组装、内容与关系检查，以及编辑校样工作台。第三方资源的许可说明随源码保留。

- JATS Journal Publishing 1.3 标签库 (<https://jats.nlm.nih.gov/publishing/tag-library/1.3/>)
- DeepSeek Chat Completions API (<https://api-docs.deepseek.com/api/create-chat-completion/>)
- 千问上下文缓存与用量字段 (<https://help.aliyun.com/zh/model-studio/context-cache>)