

word2jats：面向编辑复核的 Word 智能结构化转换

学术期刊结构化技术创新大赛 · 选题一 · 决赛技术方案说明书

参赛团队：JiangLab

在线体验：<https://word2jats.jianglab.work>

一、项目概述

word2jats 将学术论文的 Word 投稿稿转换为 JATS 1.3 XML 与配套图片，并提供可视化校样、原稿定位核对和复核记录。项目面向期刊编辑的实际工作：自动完成能够确定的结构标注，把仍需判断的内容交接给编辑，形成从稿件输入到结果导出的完整流程。

方案的核心是“模型理解结构、程序取回原文、编辑确认结果”。正文与参考文献内容以原稿位置为依据，模型负责判断结构和提供定位线索；生成后分别检查原稿内容的去向与输出内容的来源。文首作者、机构等元信息使用受约束的局部 JATS 生成通道，并进行专门核对。系统不将全文重新生成，也不把图片识别出的猜测文字写入论文。

作品包含可运行转换器、网页校样工作台、命令行接口、14 例输入与实际输出、验证工具及运行文档。核心运行不依赖本地 GPU；模型响应可缓存复用，已生成的成果可离线预览。

二、任务理解与总体方案

2.1 从视觉排版恢复出版结构

Word 中的标题、作者信息、图表和参考文献往往依靠视觉排版表达，样式名并不可靠。JATS 则要求将这些内容组织为明确的语义元素和关联关系。转换不仅要生成合法标签，还要保留研究内容、数字、符号及图表，并避免把出版后的编辑加工误当成原稿事实。

单纯依赖模板会受制于稿件体例，直接生成全文则增加改写和遗漏风险。本方案将结构识别与内容取回分工，通过原稿位置连接两者。目标格式为 JATS Journal Publishing 1.3，结构定义依据 NLM 发布的标签库与 DTD。[1]

2.2 五个相连的处理环节

环节	处理内容	产生的结果
原稿解析	读取文字、格式、表格、自动编号、 图片与公式出现位置	可寻址的源对象图
结构理解	判断文首、章节、文献边界与字段、 引文、表格结构	带原文定位线索的结构判断
原文定位与组装	将摘抄映射回原稿，归并角色，处理 冲突与不确定项	按来源组织的语义文档
XML 生成与检查	组装 JATS、外部化媒体，检查结构、 来源、覆盖及链接	XML、媒体与检查结果
校样复核与导出	浏览成品、查看原稿摘录、记录结 论，必要时修订原稿复验	可交接的成果包与复核记录

三、关键技术与工程设计

3.1 可追溯的内容取回

解析层为段落、表格、字符范围以及图片和公式的每次出现建立地址。结构理解采用这些地址与摘抄线索，程序再完成精确匹配、受控的空白与引号归一化以及上下文消歧。正文和文献字段最终取回的是原稿内容，不是模型重新写出的文字。

生成过程记录输出来源，检查过程反向寻找未覆盖的源内容。这样既能追问“这句话去了哪里”，也能追问“这个输出字段从哪里来”。图片与公式资源和出现位置分开管理，支持同一资源多处引用，不靠文件名猜图片身份。

文首的作者、机构、通讯关系采用局部 JATS 生成，以适应复杂的元信息表达；该通道通过格式校验、源外词处理与独立词级核对约束，并记录修正。它与正文的源地址通道区别明确，作者关系仍属于校样重点。

3.2 多体例参考文献与引用关联

参考文献先由两路不同问法识别条目边界，在有分歧时裁决，再逐条并行提取作者、题名、刊名、年份和卷期页。边界依据原稿中能够唯一定位的条目开头，文献完整内容与字段均从原稿取回。

字段级结构化需要同时核验实际输出范围。若存在未被字段承载的作者、年份等实义内容，系统退回整条 mixed-citation 保留原文，并提示核对，避免用结构化字段的外观掩盖内容缺失。常规著录分隔符单独处理，不将任意漏抽文字都视为标点。

数字制和作者—年份制引文分别与文末实体关联，Word 自动编号从编号定义恢复，图表提及也建立交叉引用。输出检查核对 ID 唯一性与目标闭合，语义不确定的引文另作复核提示。

3.3 表格、公式和原始媒体

原生 Word 表格按单元格与合并关系生成。以制表符或换行排出的表格由模型辅助判断列结构，机械校验未通过时保留文字并提示整理原稿。对于单行且仅一格有内容的嵌套排版小表，可将内容并入外层表头。

原生 OMML 公式通过样式表转换为 MathML，完整保留变换产生的各个节点；图像与旧式对象按其实际载体处理，不凭图片生成数学表达式。媒体按原始字节交付，并与 DOCX 内嵌资源核验。网页的 TIFF、可选 WMF 预览转换不改变下载文件。

3.4 按实际依赖并行推进

文首、正文、文献边界和引文识别同时启动。文献边界确认后即可提取字段，无须等待正文结束；正文归并后即可处理压平表格，无须等待所有文献字段结束。最终组装才汇合所需结果。

这项优化减少任务之间没有必要的等待，并保留原有内容约束与重问策略。长稿的引文识别、复杂表格及模型服务延迟仍可能成为主要耗时，系统据实显示运行阶段、耗时和缓存使用情况。

3.5 可检查、可复现的工程实现

转换器采用 Python，网页采用 FastAPI 与原生 JavaScript；命令行和网页共用同一转换入口。大文件上传支持分片、并发传输、失败重传和完整性校验。API 凭据保留在服务端，不随提交包分发。

候选结果先生成再检查，检查覆盖 XML 良构、JATS DTD、ID 与引用、媒体格式与字节、源内容覆盖、输出来源和理解状态等方面。存在未解决事项时保留候选与问题位置，供编辑处理，不把失败变成不可追查的空文件。

模型响应按请求缓存；同版代码、配置、输入及完整响应可以重放。全新模型调用和响应重放分开验证、分开计时。项目同时提供针对性单元测试、集成测试、结构对比工具与独立内容核对脚本。

四、编辑工作台与人机协作

编辑上传 Word 后，可在五个面板查看成品预览、原文核对、内容清单、合规检查和 XML 源文件。页面说明本次是重新识别、部分复用还是复用已有分析，使等待和结果来源可理解。

核对清单将具体问题关联到原稿摘录，并给出处理建议：文献未完全拆字段时核对完整著录；表格不能可靠分列时整理为 Word 原生表格；内容未覆盖时查看原段落去向。正常完成的标题拆分不作为待办，减少无须处理的提示。

每项可记录“待核对”“已核对，保留当前结果”“需修改后重新转换”，填写复核人和备注。记录包含当前 XML 的文件哈希，随成果包导出，用于说明判断针对哪一版结果。人工记录不修改 XML，也不自动覆盖机器检查结论。需要修订时，在原稿 Word 中完成，再重新上传复验。

该设计将自动化难以确定的问题转为有位置、有原文、有处理结论的编辑工作，而不是要求编辑重新标注全文。当前尚未通过真实编辑用户实验量化人工耗时的节省比例。

五、验证结果与适用范围

本次对 14 份稿件进行了逐篇全新模型调用验证：14/14 通过 JATS DTD 检查，官方 10 例均通过系统联合自动检查；4 例初赛评委测试稿中，X03 自动通过，X01、X02、X04 保留候选供核对。

逐例核对共 692 条参考文献，条目数量均与原稿一致；27 个原生 OMML 公式的完整转换文本均已保留。原稿中的 ORCID 均在输出中找到，已输出图片与 DOCX 内嵌资源字节一致，XML 引用目标无断链。

单篇冷跑耗时 38.5–339.8 秒，中位数 72.1 秒。计时包含模型调用、转换与自动检查，不含上传和人工校样时间。

样例	来源	文献条数	DTD	自动检查	冷跑耗时/秒
01	官方样例	39	通过	通过	95.3
02	官方样例	69	通过	通过	127.7
03	官方样例	56	通过	通过	75.9
04	官方样例	145	通过	通过	339.8
05	官方样例	27	通过	通过	197.7
S01	官方样例	30	通过	通过	44.9
S02	官方样例	50	通过	通过	88.7
S03	官方样例	22	通过	通过	38.5
S04	官方样例	41	通过	通过	62.4
S05	官方样例	46	通过	通过	68.3
X01	初赛评委	30	通过	待核对	49.3
X02	初赛评委	32	通过	待核对	49.5
X03	初赛评委	35	通过	通过	47.7
X04	初赛评委	70	通过	待核对	103.8

测试套件共 539 项通过、5 项跳过；网页已通过实际上传、预览、复核与下载验收。

验证输入分为主办方提供的 10 例，以及初赛评委测试在线原型时上传的 4 例。所有样例均已用于开发验证，不将它们称为独立盲测。内容核对以原稿为依据，团队整理的结构参考仅用于定位差异，不作为主办方标准答案或官方评分。

自动检查通过与无需编辑加工不是同一含义。复杂压平表格、旧式嵌入对象、手工排版公式及部分不确定引文仍需核对；部分候选中的内容覆盖问题会阻止自动通过。例如 X04 的两处文字排版公式未完整输出，需要整理原稿后复验，不属于原生 OMML 核对范围。现阶段的完整流程是自动转换加编辑复核。

六、运行与交付

提交包以 JiangLab 命名。包内 README 为上手入口，docs 提供系统设计、模块职责、实测结果与操作说明；样例数据提供 14 份原稿及对照材料，输出样例提供实际生成的 XML、图片压缩包、检查摘要与离线预览。文件清单记录来源版本及文件哈希。

运行需要 Python 3.10 以上，已在 Python 3.12 验证。安装 requirements.txt，在本地 .env 配置模型凭据，执行 `python -m webapp` 即可打开工作台。也可通过命令行转换单篇，便于与其他业务流程集成。

当前默认主流程模型为 qwen3.7-plus，文首为 qwen3.8-max，均经服务端接口调用。首次转换需要有效模型凭据与网络；离线预览展示随包的真实冻结成果，不等于离线重新推理。模型响应缓存不随提交包分发。

原型按单机服务设计，任务索引位于进程内存，重启后旧任务链接不再有效，重要结果应及时导出。面向生产部署时，需结合出版社要求配置身份认证、调用配额和稿件留存策略。

七、原创工作与使用资源

团队实现的主要工作包括源对象图与语义组织、模型任务编排、原文定位和内容取回、文献与引用处理、覆盖与来源检查，以及校样复核工作台。方案的创新体现为面向出版转换的整体约束与工作流程，而非将通用模型、标准或第三方解析库称为原创。

JATS DTD 来自 NLM 发布的规范资源；公式转换使用随项目保留的 OMML2MML.XSL 样式表；网页预览使用 NLM/NCBI JATS Preview Stylesheets，并保留来源说明。Python 文档与 XML 处理、图像读取和 Web 服务分别使用 python-docx、lxml、Pillow、FastAPI 等组件。项目源码许可见 LICENSE，第三方资源遵循各自来源与许可。

[1] NLM/NCBI, Journal Publishing Tag Library, NISO JATS Version 1.3 (June 2021): <https://jats.nlm.nih.gov/publishing/tag-library/1.3/>