

word2jats：从 Word 排版格式到 JATS XML 的智能结构化转换

学术期刊结构化技术创新大赛·选题一·决赛技术方案说明书

- 队伍：JiangLab（邓贵锋，指导老师：江海腾，浙江大学）
- 在线演示：<<https://word2jats.jianglab.work>>（校样工作台，上传 docx 即转换）
- 目标格式：JATS Journal Publishing DTD v1.3（2021-06-10），输出 100% 通过 DTD 校验

一、摘要

word2jats 把学术期刊的 Word 投稿稿自动转换为 JATS 1.3 标准 XML 与外部化图片包。方案的核心立场是：

大模型只判断结构，从不生成正文文字。正文的每个字符按源地址从 Word 原文机械取回——"内容守恒"是构造性保证（文字根本不流经模型输出口），不是事后比对补救。

决赛版在初赛方案基础上完成了一次系统性重构：层间契约从"字符串传递"升级为**源地址传递**（摘抄+落锚协议），建立**两本账**（源覆盖账+输出来源账）与**十一道出口交付门**，并针对初赛评委的四条反馈逐条实测改进。在赛题 10 个样例上，自建双评测器的缺陷合计从初赛方案的 281 降到 **164**；在赛题之外自采的 4 份真实投稿件上，参考文献从初赛方案的**整类丢失**恢复到 **30/32/35/70 条全数精确**；单篇转换实测 **101~125 秒**，比初赛的 2~3 分钟提速约一半。

二、赛题理解

选题一要求把 Word 投稿转成 JATS XML：结构上要"判断"（这段是摘要还是声明、这行是标题还是正文、这条文献的作者/年份/期刊各是哪几个字），内容上要"搬运"（一个字不许增删改，斜体上标照原样保留）。这两个要求天然互斥——判断要看懂内容，搬运不许碰内容。样式名不可靠（作者用 Normal 写标题是常态）、参考文献著录五花八门（编号制/作者-年份制/自动编号/手打编号）、公式载体多样（OMML/OLE/下划线排版），使纯规则方案脆弱；而纯生成方案会改写、丢失甚至编造文字，对学术出版是不可接受的风险。

三、技术路线：判断与搬运彻底分离

路线	结构判断	内容搬运	结论
纯规则+模板（官方基线）	死规则枚举不完长尾，样式缺失即失效	可靠	结构判断太脆
纯大模型生成	强	会改写/丢字/编造，不可复现	内容风险不可接受
本方案：模型指路，程序搬运	大模型语义判断	按源地址机械取回，构造性守恒	两者兼得

实现为四层管线：

	——这三种形态恰是初赛方案整类丢失的)
--	---------------------

为验证兼容性，我们在赛题 10 例之外自采了 4 份真实投稿件（X01-X04）做盲区测试，覆盖赛题样例没有的著录形态。初赛方案在其上参考文献输出为 0；决赛版 30/32/35/70 条全数恢复，X04 的语义元素 F1 从 0.33 升至 0.96。

五、质量评测体系与成绩

比赛不提供量化评测，我们自建了两套彼此独立、100% 无大模型参与、逐字节可复现的评测器，对照物是逐例人工核定冻结的结构参考（忠实结构化 + 可查证的标准元数据，经 35 路独立审查代理与外部复审两轮把关）：

- V1 三层缺陷清单：L0 合法层（DTD+DOCTYPE+出版规范）/ L1 忠实层（词多重集守恒，抓丢字与编造）/ L2 对位层（语义键对齐逐项比对）。产出是问题清单不是加权分。
- V2 语义树严格比对：JATS 投影成语义树逐层对齐，输出八维质量向量（元素/文本/关系 F1 等）。

决赛版终验成绩（全新缓存真实调用，样例级全并发总墙钟 851 秒）：

样例	V1 缺陷 (L0/L1/L2)	V2 元素 F1	V2 文本 F1	V2 关系 F1
01	25 (0/3/22)	0.93	0.89	0.90
02	11 (0/0/11)	0.98	0.96	0.92
03	44 (0/1/43)	0.90	0.84	0.76
04	8 (0/0/8)	0.98	0.95	0.93
05	42 (0/0/42)	0.83	0.62	0.87
S01	3 (0/0/3)	0.97	0.89	0.80
S02	4 (0/0/4)	0.97	0.91	0.78
S03	17 (0/7/10)	0.92	0.84	0.79
S04	1 (0/0/1)	0.99	0.91	0.89
S05	9 (0/0/9)	0.96	0.83	0.68
计分例合计	164（初赛方案同尺 281；重构中期 542）			
X01-X04（盲区）	109 / 145 / 53 / 78	0.59-0.96		

配套硬指标：DTD 14/14 全部通过；L0 错误全 0；词级守恒"编造词"13/14 例为 0；参考文献条数 14/14 精确；图/表交叉引用在 10 个计分例上与结构参考完全一致；图片全部逐字节等同 docx 内嵌媒体（SHA-256 校验）。

十一道交付门：8/10 计分例全门通过正式交付。两例被护栏如实点名而非静默放行——S03 的表中表（嵌套表格）属已知局限；S04 源稿未印 "Correspondence" 标签词、系统按出版体例补齐后被独立守恒器点名记账。护栏宁可拦住自己，不掩盖问题，这是我们对"学术出版可信交付"的理解。

六、工程实现

- **代码**: Python 3.9+ (3.12 验证), 核心包约 1.4 万行、**516 项自动化测试**; 依赖仅 python-docx/lxml/Pillow/PyYAML/openai/python-dotenv (网页另加 FastAPI)。JATS 1.3 DTD 全套内嵌, 离线校验。
- **并发**: 任务层 (头部/正文/切条 A/B 四路) → 条目层 (逐条文献、逐表全并发) → 进程级闸门 (默认 32 在途), 14 例整批转换总墙钟 851 秒。
- **资源消耗**: 单篇 35~146 次调用、约 41~47 万 token (默认 qwen3.7-plus, 文首任务 qwen3.8-max)。
- **可复现**: --fresh-cache 全新真实调用并留档; 同机重放零成本零网络; ReplayLLM 只读快照支持无密钥离线演示。
- **运行**:

```
```bash
```

```
PYTHONPATH=src .venv/bin/python -m word2jats convert \
```

```
 样例数据/03/初始文件.docx --journal JIN --doi 10.31083/JIN49347 -o output/
```

```
评测 (转换+打分一体):
```

```
.venv/bin/python -m scripts.eval_v1 --samples all --tag demo --fresh-cache
```

```
.venv/bin/python -m scripts.evalsuite --tag demo --samples all
```

```
```
```

七、Web 校样工作台

面向期刊生产编辑的网页应用 (FastAPI + 原生 JS, 已上线): 拖入 docx → 分片上传 (断点续传, 绕 CDN 超时) → 四阶段进度 → **校样单式结果页**: 结论先行的"可交付/待确认"印章、期刊样式成品预览 (XSLT)、**逐词"原文核对"** (输出来自原稿 / 原稿保留两个覆盖率与差异词清单——把内容守恒做成看得见的界面)、内容清单 (作者/图表/公式/文献计数)、DTD 与结构合规明细、XML 源码。下载包 = XML + 外部化图片。

八、原创性与第三方资源

核心算法 (源对象图、摘抄落锚协议、双实例对抗切条、两本账与交付门、双评测器) 均为原创。第三方仅: JATS 1.3 DTD (NISO/NLM)、OMML2MML.XSL (微软开源样式表)、JATS 预览 XSLT/CSS (NCBI 公有领域)、OpenAI 兼容 SDK。大模型 API 为方法必需组件 (理解层无规则降级档)。

九、已知边界（如实交代）

- 1. 嵌套表格（表中表）尚未展开（S03 一处表头 2 格）；
- 2. 制表符拼排的无线表格中，格网复原未过机械校验的按"一行一格"保全原文交付（05 例 14 张中 8 张，文字零丢失、结构降级）；
- 3. 参考文献内期刊名斜体的 run 级格式恢复不完整；
- 4. 手绘图形/OLE 预览缺失的对象以占位报告，不虚构内容；
- 5. 源稿未印的出版模板字（如编辑角色）不由模型补造——宁缺勿造，独立守恒器会点名任何越界。

十、附录：核验位置

| 内容 | 位置 |
|--------------|---|
| 终验转换输出（14 例） | reports/outputs/fin-submit/ |
| V1/V2 评测报告 | reports/eval_v1/fin-submit/、reports/eval_v2/fin-submit/、小结 reports/evalsuite/fin-submit/小结.md |
| 核心包 / 测试 | src/word2jats/、tests/（516 项） |
| 双评测器 | scripts/eval_v1/、scripts/eval_v2/ |
| 文档体系 | docs/（竞赛/领域/数据/设计/实现/评测/消融/网页/使用/部署 十篇） |
| 样例登记 | 样例数据/样例登记.json（14 例唯一名单） |