

word2jats

学术论文 Word → JATS XML

智能结构化技术方案说明书

参赛选题： 选题一——Word → JATS XML 的语义映射与自动化生成（word2xml）

配套提交： [可运行原型.zip](#)

在线演示： <https://word2jats.jianglab.work>

队伍： JiangLab

成员： 邓贵锋 **指导老师：** 江海腾

学校： 浙江大学

邮箱： 12415024@zju.edu.cn

摘要

word2jats 面向学术期刊生产中的 Word 结构化加工环节，将作者提交的 `.docx` 论文转换为符合 JATS Journal Publishing DTD 1.3 的 XML，并将文中图片外部化后与 XML 一并打包交付。系统覆盖题名与章节层级、作者及单位关联、ORCID、摘要、关键词、图、表、Word 公式、参考文献、出版声明和交叉引用等主要结构。

方案采用“大模型判断结构，程序回填原文并确定性生成 JATS”的技术路线。Word 原文首先被解析为保留文字、内联格式、图片和公式的中间表示，每个源块具有稳定索引；大模型只返回源块的结构类别、层级和字段边界；正文、题名、题注等内容再由程序按照索引从源文件取回。该设计利用大模型处理弱样式、跨模板排版和参考文献边界等语义问题，同时避免让模型直接改写或补写学术正文。

配套原型提供在线 Web、本地 Web、命令行和 Docker 运行方式。转换完成后可查看期刊样式预览、原文核对、内容清单、合规检查和完整 XML，并下载由 XML 与图片组成的 ZIP 交付包。JATS 1.3 DTD 随原型内置，输出无需联网获取标准文件即可完成合法性校验。

1. 赛题需求与方案定位

1.1 Word 与 JATS 之间存在语义鸿沟

Word 文档主要记录文字及其版式。题名、作者、单位、摘要、章节、图表和参考文献虽然在页面上可以被理解，但在底层文件中往往只是样式、字号、缩进、表格和普通段落的组合。同一种论文结构可能采用不同排版，同一种排版也未必表示相同语义。

JATS (Journal Article Tag Suite) 则要求将论文结构显式编码为 XML。例如，作者需要与单位建立可计算的关联，正文需要形成层级清楚的章节树，公式需要转换为 MathML，图像需要通过外部文件引用，参考文献需要尽可能拆分为作者、题名、来源、年份和卷页等字段。DTD (文档类型定义) 进一步规定了元素是否允许出现以及元素之间的合法嵌套关系。

因此，本赛题不是简单的文件格式转换，而是从“以版式为主的 Word”到“以语义为主的 JATS”的结构映射问题。

1.2 方案目标

目标	要求	对应设计
结构识别	从不同 Word 排版中识别稳定的论文语义	综合 OOXML 物理信号与大模型语义判断
内容忠实	结构化过程中不改写、翻译或概括学术正文	源块索引回填、字段子串校验、图像与公式占位

目标	要求	对应设计
标准合规	输出满足 JATS Journal Publishing DTD 1.3	确定性渲染、内置 DTD、出口合法性检查
功能完整	覆盖赛题要求的主要论文模块	front/body/back 分区识别与统一语义模型
可运行	提供可直接核验的程序和示例输入	Web、CLI、Docker、多阶段结果展示
可维护	便于更换模型、扩展期刊和增加新结构	解析、理解、语义、渲染、验证分层

1.3 输入与输出边界

系统输入为 `.docx` 学术论文，并接收期刊代码和可选 DOI。系统输出包括：

- 一份 JATS Journal Publishing 1.3 XML；
- 从 Word 提取的外部图片文件；
- XML 与图片组成的 ZIP 交付包；
- 文章结构统计、DTD 校验结果和结构检查结果；
- 供人工复核的期刊样式预览与原文核对信息。

系统负责识别和标记源稿已有内容，并按期刊配置补充固定的期刊级元数据。系统不承担论文润色、翻译、事实补写或根据图片猜测文字的任务。

2. 技术路线选择

2.1 规则与端到端生成均存在明显短板

路线	优点	主要问题
纯规则转换	结果确定、速度快、容易校验	依赖固定样式和模板；面对全篇 Normal 样式、跨段参考文献和弱版式信号时适应性不足
大模型直接生成 XML	能利用上下文理解复杂语义	模型同时控制文字与标签，可能改写内容、遗漏段落或产生不合法结构；结果难以稳定复现
本方案	大模型处理语义判断，程序控制原文和 XML 语法	需要设计受约束的中间协议，并对模型判断建立回退与验证机制


本方案不让规则独自承担全部语义识别，也不让模型直接负责整篇 XML 生成，而是将两者限定在各自更适合的环节。

2.2 三项设计原则

- 1. 原文与结构分离。** 原文由解析层保存，模型只描述“哪个源块是什么”，不承担普通正文生成。

2. 语义判断与 JATS 语法分离。大模型输出结构 JSON，JATS 元素由程序按照固定规则构造。
3. 生成与验证一体化。每次转换都执行内容核对、结构自洽检查和 DTD 校验，问题直接呈现在结果页。

2.3 总体处理流程



3. 核心技术实现

3.1 OOXML 解析保留原始内容与内联格式

.docx 本质上是 OOXML 压缩包。解析层读取正文、样式、编号和关系文件，将文档转换为有序的段落、run、表格、图片和公式对象。

Word 会因粗体、斜体、上标、下标或字体变化把连续文字拆成多个 run。如果直接按 run 进行语义识别，一个完整单词或作者单位角标可能被割裂。系统在结构判断前组合连续文字，同时保留原 run，以便生成 JATS 时恢复 **<bold>**、*<italic>*、<sup> 和 <sub> 等内联格式。

原生 Word 表格保留行、列和单元格结构；图片通过关系 ID 读取原始媒体字节；OMML 公式保留其 XML 节点，交由公式模块转换。

3.2 稳定源块索引约束模型输出

解析后的每个段落或表格被序列化为带稳定编号的内容流，例如：

```

[18] «bold,center» Abstract
[19] Objective: ...
[36] «style:Heading 1» 1. Introduction
  
```

[52] [[IMG#3]]
[53] Figure 1. Study flow chart

内容流同时提供有限的版式提示，包括粗体、斜体、居中、Word 样式、编号列表和表格形状。模型根据上下文判断结构，但输出必须引用 [idx]，而不是重新生成该段文字。

图片和公式仅以 **IMG#n**、**MATH#n** 占位符进入模型上下文。模型只能判断它们与题注、段落的位置关系，无法读取或转写其中内容，从输入层面排除“看图猜字”。

3.3 三个专门任务降低复杂度

语义理解被拆分为三个边界明确的任务：

任务	识别内容	输出重点
front	文章类型、题名、作者、单位、通讯作者、ORCID、日期、摘要、关键词	源块位置、作者字段、单位关联、正文起点
body	章节层级、普通段落、图、表、公式、出版声明	章节树、题注位置、对象占位符、声明区间
references	参考文献条目及其内部字段	条目范围、作者、题名、来源、年份、卷期页、DOI

参考文献数量过多时自动分段处理，避免单次输入过长。书籍和书籍章节增加专门的字段识别，用于编辑者、出版社、出版地和版次。

所有模型任务均要求严格 JSON 输出。字段值必须来自源文；组装阶段再次检查短字段是否为原文子串，异常字段被清空或降级，不直接进入最终 XML。

3.4 SemanticDoc 隔离语义理解与标准输出

模型返回的 JSON 不直接转换成 XML，而是先组装为独立语义模型 **SemanticDoc**。该模型统一表示作者、单位、摘要、章节、图、表、公式、声明和参考文献，并携带从源文件取回的原始 run 和媒体对象。

SemanticDoc 的作用是建立稳定接口：上游可以更换模型或调整识别策略，下游可以调整 JATS 映射规则，两者互不依赖。模型无法通过输出任意标签改变 XML 结构，渲染器也不需要重新判断段落语义。

3.5 JATS 由程序确定性构造

渲染层按 JATS 的固定骨架生成文档：

- **<front>**：期刊元数据、文章标识、题名、作者、单位、摘要和关键词；
- **<body>**：章节、段落、图、表和公式；
- **<back>**：声明、致谢和参考文献。

作者与单位、正文与图表、正文与参考文献之间通过 **id** 和 **rid** 建立交叉引用。元素 ID 统一生成并检查唯一性；只有目标存在时才建立引用，避免产生悬空 **xref**。

期刊名、ISSN、出版者和固定许可信息从本地期刊配置读取，不由模型推测。新增期刊时可扩展配置，而不需要改动核心处理流程。

3.6 图片、表格、公式和参考文献处理

图片。 图片从 Word 媒体包提取后直接写入输出目录，不重新编码；JATS 使用 **<graphic xlink:href="...">** 指向外部文件。图题文字从原 Word 段落取回。

表格。 原生 Word 表格按单元格网格转换；制表符分隔的文本表可重建为表格；整张以图片存在的表保持为外部图片，不执行文字猜测。

公式。 Word 中的 OMML 公式通过原型内置的 **OMML2MML.XSL** 转换为 MathML，并按原位置生成 **<inline-formula>** 或 **<disp-formula>**。仅以图片存在的公式不执行 OCR。

参考文献。 字段识别可靠时生成结构化 **<element-citation>**；字段不完整或边界不可靠时保留整条原文，以 **<mixed-citation>** 输出。该回退优先保证内容可追溯，不为追求字段齐全而补造数据。

3.7 出口验证形成交付闭环

每次转换结束前执行三类检查：

- 1. 内容核对：** 比较源 Word 与输出 XML 中的文字，报告可能新增和可能遗漏的词汇，供人工复核；
- 2. 结构自治：** 检查 ID 唯一性、交叉引用目标、图片文件、公式表示和表格结构；
- 3. 标准合法性：** 检查 XML、DOCTYPE 和命名空间，并使用随原型提供的 JATS Publishing 1.3 DTD 离线校验。

Web 结果页将检查结论分为“可交付”与“待确认”。DTD 或高等级结构检查不通过时不会隐藏问题，完整诊断和 XML 原文仍可查看。

4. 功能实现范围

4.1 赛题功能逐项对应

赛题功能	实现状态	实现方式
标题层级	已实现	综合编号、样式、版式和语义识别多级章节，生成嵌套 <sec>
作者信息	已实现	识别姓名、顺序、通讯作者、共同贡献和邮箱
作者单位	已实现	识别单位并通过 xref rid 建立作者—单位关联

赛题功能	实现状态	实现方式
ORCID	已实现	规范化 ORCID, 生成 <code><contrib-id contrib-id-type="orcid"></code>
关键词	已实现	识别标题和分隔项, 生成 <code><kwd-group></code>
摘要	已实现	支持普通摘要和带小标题的结构化摘要
图片	已实现	识别图题、外部化原图、生成 <code><graphic></code> 引用
表格	已实现	支持原生 Word 表格、制表符表和图片表
列表	部分实现	读取 Word 编号并保留列表文字; 当前按段落输出, 尚未生成专门的 <code><list>/<list-item></code>
数学公式	已实现并有限定	OMML 转 MathML; 纯图片公式不执行 OCR
参考文献	已实现	结构化著录与自由文本回退并存
交叉引用	已实现	识别图、表和文献引用并建立 <code>id/rid</code>
出版声明	已实现	识别基金、利益冲突、伦理、作者贡献、致谢和数据可用性等声明

4.2 交付结果同时面向机器与人工

JATS XML 用于后续出版系统、数据库交换、全文检索和长期保存; 外部图片与 XML 一起组成完整数据包。与此同时, Web 工作台提供期刊样式预览和原文核对, 使编辑人员无需直接阅读 XML 也能检查图表、章节和正文是否完整。

这种双重输出避免把“通过 DTD”误当成“内容一定正确”。标准校验负责判断结构是否合法, 人工预览和核对负责判断语义是否符合原稿, 两者共同构成交付依据。

5. 方案创新点

创新点	技术机制	实际作用
带索引的受约束语义映射	模型输出源块索引、类型和字段边界, 正文按索引回填	保留模型语义理解能力, 同时切断模型直接改写普通正文的路径
内容与结构双通道	IR 保存原文与格式, 结构 JSON 只保存判断结果	结构判断错误不会自动变成文字改写, 便于单独修正识别规则
图片与公式占位协议	模型只接收对象编号, 不接收图像字节或公式转写结果	避免 OCR 或视觉猜测引入不存在的学术内容
语义模型与 JATS 渲染解耦	<code>SemanticDoc</code> 作为稳定接口, JATS 由程序构造	模型可替换、标准映射可维护, 输出结构不受模型自由格式影响
结构化失败的保真回退	参考文献字段不可靠时保留整条原文	将失败方向控制为“结构粒度降低”, 而不是补造字段

创新点	技术机制	实际作用
面向编辑的验证闭环	DTD、结构检查、原文核对和预览在同一结果页呈现	将算法输出转化为可审查、可签收的出版交付物

核心创新不在于单独使用大模型，而在于重新划分模型与确定性程序的职责：模型解决“这段是什么”，程序解决“原文是什么”和“JATS 应如何合法表达”。

6. 工程实现与可运行原型

6.1 技术栈与代码结构

原型采用 Python 3.12。`python-docx` 与 `lxml` 负责 Word/XML 处理和 DTD 校验，`Pillow` 负责图片识别与预览转换，`FastAPI/Uvicorn` 提供 Web 服务，模型通过 `OpenAI` 兼容接口调用。

可运行原型/		
src/word2jats/		
parse/		Word/OOXML 解析
understand/		内容流、语义理解与组装
semantic/		SemanticDoc 语义模型
render/		front/body/back 确定性渲染
build/		图片、公式、JATS 元素和交叉引用
validate/		DTD 与结构检查
verify/		内容核对
llm/		模型适配与磁盘缓存
resources/		JATS 1.3 DTD、XSLT、期刊配置
webapp/		Web 后端、前端和预览资源
示例输入/		可直接用于验收的 Word 文件
README.md		运行说明
requirements.txt		依赖清单
pyproject.toml		Python 项目元数据
Dockerfile		容器运行定义

6.2 Web 工作台降低验收与使用门槛

Web 服务直接调用与命令行相同的转换管线，不维护另一套转换逻辑。文件提交后返回任务 ID，后台执行转换，前端轮询进度并依次展示“读取 Word—识别结构—生成 JATS—合规检查”等阶段。

结果页包含：

- **成品预览：**将 JATS 服务端渲染为期刊样式 HTML；
- **原文核对：**展示输出来源覆盖和源文保留情况，以及需要人工确认的词条；
- **内容清单：**列出作者、单位、关键词、章节、图表、公式和参考文献数量；
- **合规检查：**展示 DTD 和结构检查结论；
- **XML 源文件：**供技术人员查看完整 JATS；
- **交付包下载：**下载 XML 与外部图片组成的 ZIP。

主要 API 包括转换提交、任务状态、结果、预览、图片和下载接口；大文件支持分片上传与断点续传。

6.3 成本、复现与安全控制

模型响应按请求内容写入本地磁盘缓存。相同输入、期刊和 DOI 再次转换时可复用已有响应，减少重复调用费用，并固定已经获得的模型判断结果。默认使用 `qwen3.7-plus`，模型适配层也支持其他 OpenAI 兼容服务。

API Key 仅由服务端从 `.env` 读取，不进入浏览器或转换结果。图片访问执行路径边界检查；上传文件设有大小限制；用户可见错误不包含服务器路径和异常堆栈。Docker 构建时不复制 `.env`，密钥通过运行参数注入。

7. 质量保证与验证结果

7.1 标准合法性由运行时直接验证

JATS 1.3 DTD 及其实体文件完整包含在原型中。每次转换生成 XML 后立即执行离线 DTD 校验，并检查精确 DOCTYPE、命名空间、ID 唯一性和交叉引用目标。评审可在 Web “合规检查” 页或命令行输出中直接查看结果，无需依赖额外报告。

使用赛题提供的 10 份 Word 样例进行回归转换，10 份输出均通过 JATS Journal Publishing 1.3 DTD。该结果说明输出满足标准语法和内容模型要求；DTD 通过不等同于所有语义字段均达到人工标注水平，因此系统仍保留预览、内容清单和原文核对环节。

7.2 配套示例可复核主要处理链路

原型内置 `示例输入/初始文件.docx`。按推荐参数转换后，结果页应识别并展示以下主要结构：

核验项	预期结果
文章号	HSF49106
作者 / 单位 / 关键词	4 / 2 / 4
正文章节	5
图 / 表	4 / 10
参考文献	27
交叉引用	60
DTD 校验	通过

该示例同时覆盖文件上传、结构识别、图片外部化、表格转换、参考文献结构化、交叉引用、服务端预览和 ZIP 下载。具体耗时受网络状况、模型队列和运行环境影响，通常约为 1—2 分钟。

7.3 质量判断采用“机器检查 + 人工复核”

机器检查能够确定 XML 是否格式良好、是否符合 DTD、引用是否悬空、图片是否存在，但不能完全替代对章节归属、题注边界和参考文献字段的业务判断。原型因此不以单一分数代替质量结论，而是将合法性、结构统计、内容差异和成品预览同时提供给评审或编辑人员。

这一质量策略与实际出版加工一致：自动化负责识别、生成和发现问题，人工负责确认少量有歧义的语义边界。

8. 运行与验收

8.1 推荐验收顺序

1. 通过在线地址快速体验完整页面和转换流程；
2. 解压 [可运行原型.zip](#)，按 README 在本地启动 Web 服务；
3. 使用原型自带示例完成一次转换，核对结构统计、DTD 结果、预览和 ZIP 下载；
4. 按需使用命令行或 Docker 验证独立运行能力。

8.2 在线体验

浏览器访问：<https://word2jats.jianglab.work>

在线实例与提交原型使用相同的应用和转换管线，可直接上传 Word 进行体验。公网服务受外部网络和模型服务状态影响；如遇网络不可达，以配套原型的本地运行结果为准。

8.3 本地 Web 运行

环境要求为 Python 3.12 和可访问模型接口的网络。解压后在 [可运行原型](#) 目录执行：

```
python3.12 -m venv .venv
.venv/bin/python -m pip install -r requirements.txt
.venv/bin/python -m webapp
```

浏览器打开 <http://127.0.0.1:8000>，使用以下参数：

- 输入文件：[示例输入/初始文件.docx](#)
- 期刊：[HSF](#)
- DOI：[10.31083/HSF49106](#)

8.4 命令行运行

```
PYTHONPATH=src .venv/bin/python -m word2jats convert \
"示例输入/初始文件.docx" \
--journal HSF \
--doi 10.31083/HSF49106 \
-o output
```

输出目录包含 [HSF49106.xml](#) 和从 Word 提取的图片，终端同时显示文章结构统计与校验结果。

8.5 Docker 运行

```
docker build -t word2jats .
docker run --rm --env-file .env -p 8000:8000 word2jats
```

浏览器打开 <http://127.0.0.1:8000> 即可使用。

8.6 验收专用 API Key

配套原型的 `.env` 已配置仅用于本次赛事验收的 API Key，并预置约 10 元调用额度。评审无需另行申请密钥即可运行示例。API Key 只由后端读取，不会显示在前端或写入输出文件。

若验收时额度耗尽或密钥失效，可在 `.env` 中替换 `DASHSCOPE_API_KEY` 和对应的兼容接口地址后重新启动服务。有效模型接口是完成语义转换的必要条件；无有效 Key 时产生的空结构不能作为有效结果。

9. 原创性与第三方资源边界

核心处理链路、源块索引协议、三段语义理解、SemanticDoc、JATS 渲染、交叉引用、内容核对、验证编排、Web 工作台和模型适配均为本项目实现。

项目使用公开标准资源和通用基础库，边界如下：

资源	用途	与核心方案的边界
JATS Journal Publishing 1.3 DTD	输出合法性校验	标准文件，不参与语义识别
OMML2MML.XSL	OMML 转 MathML	通用公式格式转换资源
NCBI JATS 预览 XSLT/CSS	Web 端成品预览	仅用于显示，不改变交付 XML
python-docx、lxml、Pillow、FastAPI 等	文档、XML、图像和 Web 基础能力	通过公开接口组合使用
云端或本地大语言模型	返回受约束的结构判断	可替换推理后端，不直接构造 JATS 或普通正文

第三方预览资源的来源说明随原型保留，标准资源、第三方资源和核心代码在目录中分开存放。

10. 已知边界与后续扩展

- 列表结构尚未专门输出。** Word 编号已被解析并用于语义提示，列表文字能够保留；当前仍按段落生成，后续可在 SemanticDoc 中增加列表对象并映射为 `<list>/<list-item>`。
- 纯图片公式不转写。** 无 OMML 的图片公式不执行 OCR，避免错误识别改变数学含义。后续若引入公式 OCR，需要增加置信阈值和人工确认。
- 弱信号结构存在歧义。** 无样式、无编号的提示框、小标题、复杂图题和跨列表头可能存在多种合理结构，需要通过结果页复核。
- 模型服务是必要依赖。** 网络、余额或模型响应异常会影响首次转换；磁盘缓存只能复用已经处理过的相同请求。
- 当前 Web 原型面向单机验收。** 任务状态保存在进程内存中，服务重启后不保留，不具备多机调度和用户权限体系。生产部署可替换为持久化任务队列、对象存储和数据库。
- 输入格式限定为 .docx。** 旧版 .doc、PDF 和扫描件不在当前范围。

上述边界不影响原型对赛题核心流程的演示和核验，也明确了从竞赛原型向生产系统演进时需要补充的能力。

11. 结论

word2jats 已形成从 Word 解析、语义结构判断、JATS 1.3 确定性渲染、图片外部化、内容与结构验证到 Web 交付的完整可运行链路。

方案的核心价值在于以受约束的大模型解决跨模板语义识别问题，同时将原文控制权和 JATS 语法控制权保留在确定性程序中。配套原型能够直接接受 Word 输入、产生 XML 与图片交付包，并通过 DTD、结构检查、原文核对和成品预览支持评审验收与编辑复核。

附录：配套原型核验位置

核验内容	解压后的文件或目录
运行说明	README.md
示例输入	示例输入/初始文件.docx
核心转换入口	src/word2jats/pipeline.py
Word 解析	src/word2jats/parse/
语义理解	src/word2jats/understand/
JATS 渲染	src/word2jats/render/
内容与结构验证	src/word2jats/verify/、src/word2jats/validate/
JATS 1.3 DTD	src/word2jats/resources/dtd/
公式转换资源	src/word2jats/resources/OMML2MML.XSL
Web 服务入口	webapp/app.py
Web 前端	webapp/static/
依赖清单	requirements.txt、pyproject.toml
容器运行定义	Dockerfile
验收配置	.env、.env.example